

A large, stylized illustration of a penguin is centered on the page. The penguin is depicted in a dynamic, leaping pose, with its wings spread wide. The body is primarily grey, while the belly is white. A prominent orange-yellow curved line, resembling a wing or a tail feather, sweeps across the penguin's side. The background is a solid light beige color.

Análisis PCA y Clustering sobre el dataset Palmer Penguins

Dayron Rodríguez Díaz

ÍNDICE

Índice	2
Introducción	3
Desarrollo	4
Metodología y herramientas empleadas	4
Carga de datos y preparación inicial de la serie	4
Estadísticas básicas descriptivas sobre el conjunto de datos.....	5
Visualizaciones para obtener información sobre los datos.....	6
Matriz de correlaciones y su representación gráfica	7
Análisis de componentes principales (PCA) con datos estandarizados y selección del número adecuado de componentes.....	8
PCA con el número de componentes retenidos e interpretación de variables, observaciones e índice físico	10
Determinación del número de grupos mediante agrupamiento jerárquico y análisis del dendrograma	14
Agrupamiento k-means y selección del número óptimo de grupos mediante el método del codo.....	18
Validación del agrupamiento mediante métricas como la silueta y evaluación de la calidad de los grupos	20
Comparación entre agrupamiento jerárquico y k-means en las asignaciones de grupos	22
Interpretación de los grupos identificados y análisis de patrones entre las especies de pingüinos	23
Resumen de hallazgos, conclusiones y limitaciones del análisis de agrupamiento	24
Limitaciones y desafíos	24

INTRODUCCIÓN

El análisis de datos multivariante constituye una de las herramientas fundamentales en el ámbito de la estadística aplicada y el aprendizaje automático, permitiendo extraer patrones y estructuras subyacentes en conjuntos de datos de alta dimensionalidad. En este contexto, el presente trabajo aborda el estudio morfológico de tres especies de pingüinos del archipiélago Palmer —*Adelie*, *Chinstrap* y *Gentoo*— a través de un enfoque metodológico que integra técnicas de reducción de dimensionalidad y agrupamiento no supervisado.

Para ello, se emplea el conjunto de datos *Palmer Penguins*, ampliamente utilizado en la literatura como referencia para la validación de métodos de clasificación y clustering. Dicho dataset recoge mediciones morfológicas de 344 individuos, incluyendo variables como la longitud y profundidad del pico, la longitud de la aleta y la masa corporal, junto con variables categóricas como la especie, la isla de procedencia y el sexo.

El análisis se estructura en tres bloques principales. En primer lugar, se realiza un Análisis Exploratorio de Datos (EDA) que comprende el estudio de estadísticos descriptivos, el análisis de correlaciones entre variables numéricas mediante el coeficiente de Pearson, y el estudio de asociaciones entre variables categóricas y numéricas a través de ANOVA con Eta^2 y la V de Cramér. En segundo lugar, se aplica el Análisis de Componentes Principales (PCA) con el objetivo de reducir la dimensionalidad del espacio de variables, identificar las direcciones de mayor variabilidad y facilitar la visualización de las observaciones. Finalmente, se implementan y comparan dos métodos de clustering —jerárquico con enlace de Ward y K-Means— con el fin de evaluar la capacidad de cada algoritmo para recuperar la estructura natural de los datos sin hacer uso de las etiquetas de especie.

El objetivo último de este trabajo es demostrar cómo la combinación de técnicas de reducción de dimensionalidad y agrupamiento no supervisado permite identificar de forma eficaz grupos morfológicamente coherentes, cuya correspondencia con las especies biológicas reales sirve como criterio de validación externa de los resultados obtenidos.

DESARROLLO

METODOLOGÍA Y HERRAMIENTAS EMPLEADAS

Para el desarrollo de este proyecto se ha utilizado el lenguaje de programación **Python (versión 3.11)**, junto con un conjunto de librerías especializadas que permiten abordar de manera integral el análisis de componentes principales y clustering.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import os
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
from scipy import stats
from scipy.stats import chi2_contingency
from scipy.spatial import distance
import scipy.cluster.hierarchy as sch
from sklearn.cluster import KMeans
from sklearn.cluster import DBSCAN
from sklearn.metrics import silhouette_score
from sklearn.metrics import silhouette_samples
```

Imagen 1 Conjunto de librerías utilizadas en el estudio

A lo largo del documento se presentan los fragmentos de código utilizados y se analizan los resultados obtenidos en cada etapa del estudio.

CARGA DE DATOS Y PREPARACIÓN INICIAL DE LA SERIE

```
df = sns.load_dataset("penguins")

df = df.dropna()

df.isna().sum()
```

	0
species	0
island	0
bill_length_mm	0
bill_depth_mm	0
flipper_length_mm	0
body_mass_g	0
sex	0

Imagen 2 Carga del dataset y limpieza de valores nulos

Una vez importado el *dataset* mediante el método `load_dataset` de la librería Seaborn, se procede a eliminar los valores nulos utilizando `df.dropna()`. De este modo se obtiene un *dataset* limpio y listo para comenzar el análisis.

ESTADÍSTICAS BÁSICAS DESCRIPTIVAS SOBRE EL CONJUNTO DE DATOS.

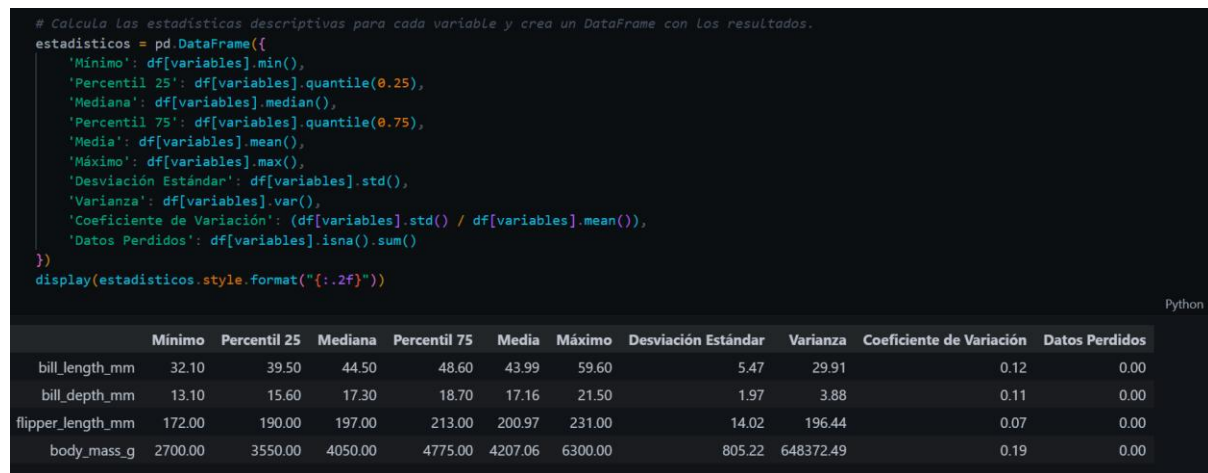


Imagen 3 Estadísticos de las variables numéricas

A través del código de la imagen 3 obtenemos los estadísticos principales del conjunto de observaciones.

El análisis descriptivo de las variables morfológicas del conjunto de datos muestra que, en general, las medidas presentan distribuciones relativamente equilibradas. En el caso de **bill_length_mm**, la media (43.99 mm) y la mediana (44.50 mm) son muy similares, lo que sugiere una distribución aproximadamente simétrica. Los valores observados oscilan entre 32.10 mm y 59.60 mm, con una desviación estándar de 5.47 mm, lo que indica una variabilidad moderada en la longitud del pico entre los individuos analizados.

Para la variable **bill_depth_mm**, la media (17.16 mm) y la mediana (17.30 mm) también son muy cercanas, lo que apunta igualmente a una distribución bastante equilibrada. Además, presenta una desviación estándar relativamente baja (1.97 mm), lo que indica que esta característica muestra poca dispersión respecto a su media y, por tanto, una mayor homogeneidad entre los individuos.

En cuanto a **flipper_length_mm**, se observa una media de 200.97 mm y una mediana de 197.00 mm, lo que podría sugerir una ligera asimetría hacia valores más altos. Los valores se sitúan entre 172 mm y 231 mm, con una desviación estándar de 14.02 mm. Sin embargo, su coeficiente de variación (0.07) indica que, en términos relativos, es la variable con menor variabilidad dentro del conjunto analizado.

Por último, la variable **body_mass_g** presenta la mayor dispersión. Su media es de 4207.06 g y su mediana de 4050 g, mostrando una diferencia mayor que en las variables anteriores, lo que sugiere una ligera asimetría positiva en la distribución del peso corporal. Los valores varían entre 2700 g y 6300 g, con una desviación estándar de 805.22 g y el coeficiente de variación más alto (0.19), indicando que la masa corporal es la característica con mayor variabilidad relativa entre los pingüinos.

VISUALIZACIONES PARA OBTENER INFORMACIÓN SOBRE LOS DATOS.

Análisis de dispersión




Imagen 4 Pairplot de las variables numéricas

Para analizar la estructura de los datos se utilizó un **pairplot**, una visualización que permite explorar simultáneamente múltiples relaciones entre variables. A diferencia de un único gráfico de dispersión, esta representación combina en una sola figura varias visualizaciones: histogramas que muestran la distribución individual de cada variable y múltiples gráficos de dispersión que permiten analizar las relaciones entre todos los pares de variables. De esta forma, el pairplot ofrece una visión más completa de la estructura del dataset.

En la diagonal del gráfico se observan los histogramas de cada variable, que muestran la distribución de las medidas morfológicas analizadas. En general, las

variables presentan distribuciones relativamente continuas, aunque en algunos casos se aprecia la presencia de varios picos, lo que podría indicar la existencia de distintos grupos dentro de los datos.

En los gráficos de dispersión se identifican relaciones interesantes entre algunas variables. Por ejemplo, **flipper_length_mm** y **body_mass_g** muestran una clara relación positiva, indicando que los individuos con mayor longitud de aleta tienden a presentar mayor masa corporal. Este patrón sugiere una fuerte asociación entre ambas características morfológicas.

Asimismo, al analizar combinaciones como **bill_length_mm** con **bill_depth_mm**, o **bill_depth_mm** con **flipper_length_mm**, se observan **agrupamientos diferenciados de puntos**. Estos patrones sugieren la presencia de subgrupos dentro del conjunto de datos, lo cual es consistente con la existencia de diferentes especies de pingüinos en el dataset.

MATRIZ DE CORRELACIONES Y SU REPRESENTACIÓN GRÁFICA




Imagen 5 Matriz de correlación de Pearson

La matriz de correlaciones presentada recoge las relaciones lineales entre las cuatro variables morfológicas numéricas del dataset: longitud del pico (**bill_length_mm**), profundidad del pico (**bill_depth_mm**), longitud de la aleta (**flipper_length_mm**) y masa corporal (**body_mass_g**). La relación más fuerte de signo positivo se observa entre **flipper_length_mm** y **body_mass_g**, con $r = 0.87$, lo que indica una asociación muy alta: los pingüinos con aletas más largas presentan sistemáticamente una mayor masa corporal, resultado que tiene una explicación biológica clara dado que ambas variables son indicadoras del tamaño general del individuo. En segundo lugar, **bill_length_mm** y **flipper_length_mm** muestran una correlación de $r = 0.65$, también positiva y moderadamente alta, lo que sugiere que los pingüinos con picos más largos tienden igualmente a tener aletas más desarrolladas. De forma similar,

bill_length_mm y body_mass_g presentan $r = 0.59$, reforzando la idea de que la longitud del pico forma parte del patrón general de tamaño corporal.

En cuanto a las correlaciones negativas, la profundidad del pico (bill_depth_mm) es la única variable que mantiene correlación negativa con todas las demás, lo cual constituye el rasgo más llamativo de la matriz. Con flipper_length_mm alcanza $r = -0.58$, con body_mass_g $r = -0.47$, y con bill_length_mm $r = -0.23$, lo que significa que, a nivel global del dataset, los pingüinos con picos más profundos tienden a tener aletas más cortas, menor masa corporal y picos más cortos. En consecuencia, respondiendo directamente a la pregunta planteada, las variables con mayor correlación inversa son **bill_depth_mm y flipper_length_mm**, con $r = -0.58$, siendo esta la correlación negativa más intensa de toda la matriz e indicando que profundidad de pico y longitud de aleta evolucionan en sentidos opuestos entre los individuos del dataset. No obstante, esta interpretación debe matizarse con un fenómeno estadístico conocido como la **Paradoja de Simpson**: al analizar el dataset sin distinguir por especie, la especie Gentoo —caracterizada por picos poco profundos, aletas largas y mayor masa corporal— invierte artificialmente las correlaciones globales, siendo altamente probable que dentro de cada especie por separado la mayoría de estas correlaciones sean positivas. Esto pone de manifiesto la necesidad de controlar por variables categóricas relevantes, en este caso la especie, antes de extraer conclusiones sobre las relaciones entre características morfológicas.

ANÁLISIS DE COMPONENTES PRINCIPALES (PCA) CON DATOS ESTANDARIZADOS Y SELECCIÓN DEL NÚMERO ADECUADO DE COMPONENTES

```
datos_para_escalar = df[variables].dropna()
scaler = StandardScaler()
datos_std_scaled = scaler.fit_transform(datos_para_escalar)

datos_std = pd.DataFrame(
    datos_std_scaled,
    columns=['{}_z'.format(col) for col in variables],
    index=datos_para_escalar.index
)
display(datos_std.style.format("{:.2f}"))
```

[13] ✓ 0.0s

	bill_length_mm_z	bill_depth_mm_z	flipper_length_mm_z	body_mass_g_z
0	-0.90	0.78	-1.43	-0.57
1	-0.82	0.12	-1.07	-0.51
2	-0.68	0.42	-0.43	-1.19
4	-1.34	1.09	-0.57	-0.94
5	-0.86	1.75	-0.78	-0.69

Imagen 6 Estandarización de los datos

El primer paso para realizar un análisis de componentes principales sería estandarizar los datos como se realiza en la imagen 6.

La estandarización es necesaria porque las variables se encuentran en escalas diferentes (mm y gramos). Sin esta transformación, variables con mayor varianza, como body_mass_g, dominarían el cálculo de las componentes principales.

Tras estandarizar las cuatro variables morfológicas, se ajustó un PCA con un máximo de 4 componentes principales, obteniendo la siguiente tabla de autovalores y varianza explicada:

	Autovalores	Variabilidad Explicada	Variabilidad Acumulada
Componente 1	2.75	68.63	68.63
Componente 2	0.78	19.45	88.09
Componente 3	0.37	9.22	97.30
Componente 4	0.11	2.70	100




Imagen 7 Variabilidad explicada por componente principal

La primera componente principal (CP1) concentra el 68.63% de la varianza total, lo que indica que existe una dirección dominante de variabilidad en los datos que recoge el patrón general de tamaño corporal de los pingüinos. La segunda componente (CP2) aporta un 19.45% adicional, alcanzando conjuntamente el 88.09% de la varianza explicada acumulada.

Aplicando el criterio de Kaiser que establece retener únicamente los componentes con autovalor mayor que 1 únicamente CP1 supera dicho umbral ($\lambda = 2.75$), aunque la caída pronunciada entre CP1 y CP2 visible en el gráfico de varianza explicada (scree plot) sugiere que CP2 aporta información relevante adicional. Atendiendo además al criterio de varianza acumulada, con dos componentes se supera el umbral del 85% habitualmente exigido en la práctica.

Por tanto, el número adecuado de componentes para representar eficientemente la variabilidad de las especies de pingüinos es 2, ya que con CP1 y CP2 se captura el

88.09% de la información total del dataset, logrando una reducción de dimensionalidad de 4 a 2 variables con una pérdida mínima de información.

PCA CON EL NÚMERO DE COMPONENTES RETENIDOS E INTERPRETACIÓN DE VARIABLES, OBSERVACIONES E ÍNDICE FÍSICO

Una vez determinado que dos componentes principales son suficientes para representar eficientemente la variabilidad del dataset, se procede a ajustar el PCA definitivo reteniendo únicamente CP1 y CP2.

Autovectores y correlaciones con las componentes

Los autovectores obtenidos recogen los pesos con los que cada variable original contribuye a cada componente principal. La tabla resultante es la siguiente:

	Autovector 1	Autovector 2
Bill_length_mm_z	0.45	0.60
Bill_depth_mm_z	-0.40	0.80
Flipper_length_mm_z	0.58	0.01
Body_mass_g_z	0.55	0.08

A partir de estos pesos, se calculan las puntuaciones de cada observación en las nuevas componentes mediante la transformación lineal correspondiente, y posteriormente se obtienen las correlaciones entre las variables originales estandarizadas y cada componente principal, obteniendo la siguiente tabla:

	Componente 1	Componente 2
Bill_length_mm_z	0.75	0.53
Bill_depth_mm_z	-0.66	0.70
Flipper_length_mm_z	0.96	0.01
Body_mass_g_z	0.91	0.07

Estas correlaciones permiten interpretar el significado de cada componente con mayor precisión que los autovectores por sí solos, ya que tienen en cuenta la varianza de cada variable. CP1 presenta correlaciones altas y positivas con flipper_length_mm ($r = 0.96$) y body_mass_g ($r = 0.91$), y una correlación negativa moderada con

bill_depth_mm ($r = -0.66$), por lo que puede interpretarse como un índice general de tamaño corporal: valores altos corresponden a pingüinos grandes, con aletas largas, mayor peso y picos poco profundos. CP2, por su parte, está dominada por bill_depth_mm ($r = 0.70$) y bill_length_mm ($r = 0.53$), capturando por tanto la morfología específica del pico, independientemente del tamaño corporal del individuo.

Gráfico de $\cos^2$ — Calidad de representación




Imagen 8 Varianza explicada por cada variable ($\cos^2$)

El gráfico de barras de $\cos^2$ muestra la calidad de representación de cada variable en el plano formado por las dos componentes retenidas. Todas las variables presentan valores elevados: bill_depth_mm_z y flipper_length_mm_z superan el 0.90, mientras que bill_length_mm_z y body_mass_g_z se sitúan ligeramente por encima de 0.80. Esto confirma que el plano CP1–CP2 captura adecuadamente la información de todas las variables originales, sin que ninguna quede mal representada.

Círculo de correlaciones — Interpretación de las variables




Imagen 9 Círculo de correlaciones PCA

El círculo de correlaciones permite interpretar el significado de cada componente a partir de la dirección y longitud de los vectores. Se observan dos grupos claramente diferenciados. Por un lado, flipper_length_mm_z y body_mass_g_z apuntan hacia la derecha sobre el eje CP1, con vectores largos y próximos al eje horizontal, lo que indica una correlación positiva alta con CP1 y prácticamente nula con CP2. Por otro lado, bill_depth_mm_z apunta hacia el cuadrante superior izquierdo, mostrando una correlación negativa con CP1 y positiva con CP2. Finalmente, bill_length_mm_z se sitúa en el cuadrante superior derecho, con contribuciones positivas a ambas componentes, siendo su aportación a CP2 la más destacada de todas las variables.

En consecuencia, CP1 puede interpretarse como un índice general de tamaño corporal: valores altos corresponden a pingüinos grandes, con aletas largas, mayor masa y picos poco profundos, mientras que valores bajos corresponden a individuos más pequeños. CP2 captura la morfología específica del pico: diferencia pingüinos con picos largos y relativamente profundos (valores altos) de aquellos con picos cortos y poco profundos (valores bajos), con independencia del tamaño corporal general.

Gráfico de observaciones — Separación por especie




Imagen 10 PCA — Observaciones




Imagen 11 PCA Plot coloreado por especies

El scatter plot sin color (Imagen 10) ya mostraba una estructura en dos nubes claramente separadas a lo largo de CP1, con una nube en la zona negativa y otra en la zona positiva. Al colorear los puntos por especie, esta estructura se hace completamente interpretable.

Gentoo (verde) ocupa el extremo derecho del eje CP1, con valores positivos altos, lo que confirma que es la especie de mayor tamaño corporal general: aletas más largas, mayor masa y picos menos profundos. Se distribuye principalmente en la franja central y baja de CP2, lo que indica que no se distingue especialmente por la morfología del pico respecto a la media.

Adelie (azul) se concentra en el extremo izquierdo de CP1, con valores negativos, siendo la especie más pequeña morfológicamente. En CP2 presenta valores dispersos entre -1 y 1 , sin una posición especialmente destacada.

Chinstrap (naranja) destaca claramente en CP2, ocupando la zona superior del gráfico con los valores más altos en esta componente. Esto refleja que, a pesar de tener un tamaño corporal similar a Adelie en CP1, se distingue nítidamente por tener picos proporcionalmente más largos y profundos. Esta separación vertical entre Adelie y Chinstrap es precisamente el motivo por el que retener CP2 resulta imprescindible: sin ella, ambas especies serían prácticamente indistinguibles.

Dado que CP1 concentra el 68.63% de la variabilidad total y recoge el patrón dominante de tamaño corporal, puede utilizarse directamente como índice que valora de forma conjunta las características físicas de un pingüino. Dicho índice se construye como la siguiente combinación lineal de las variables estandarizadas, empleando los pesos del primer autovector:

$$\text{Índice} = 0.45 \times \text{bill_length_z} - 0.40 \times \text{bill_depth_z} + 0.58 \times \text{flipper_length_z} + 0.55 \times \text{body_mass_z}$$

Un valor alto del índice corresponde a un pingüino de gran tamaño, con aletas largas, elevada masa corporal y pico largo, pero poco profundo. Un valor bajo indica lo contrario. Aplicando este índice al conjunto de datos, los valores medios por especie son los siguientes:

Gentoo: obtiene el valor más alto (2.00), siendo la especie morfológicamente más grande

Adelie: el más bajo (-1.47) como la más pequeña

Chinstrap: presenta un valor intermedio (-0.39).

Estos resultados son coherentes con lo observado en el scatter plot y con el conocimiento biológico de las tres especies.

DETERMINACIÓN DEL NÚMERO DE GRUPOS MEDIANTE AGRUPAMIENTO JERÁRQUICO Y ANÁLISIS DEL DENDROGRAMA

Matriz de distancias Euclidianas

Como punto de partida del análisis de clustering, se calcula la matriz de distancias euclidianas entre todas las observaciones del dataset, utilizando los datos morfológicos estandarizados (datos_std). Esta matriz recoge, para cada par de pingüinos, cuán diferentes son entre sí en términos de sus características físicas conjuntas. A modo ilustrativo, se muestra la submatriz correspondiente a las 5 primeras observaciones:

Matriz de Distancia (primeras 5x5)					
	0	1	2	3	4
0	0.00	0.76	1.25	1.08	1.17
1	0.76	0.00	1.00	1.28	1.66
2	1.25	1.00	0.00	0.98	1.47
3	1.08	1.28	0.98	0.00	0.88
4	1.17	1.66	1.47	0.88	0.00

Imagen 12 Matriz de distancias

Heatmap de la Matriz de Distancias Euclidianas




Imagen 13 Heatmap de la matriz total

Para visualizar la estructura global de similitudes entre los pingüinos del dataset, se representa la matriz de distancias completa mediante un heatmap. Los colores oscuros (morado/negro) indican distancias pequeñas, es decir, pingüinos muy similares entre sí, mientras que los colores claros (verde/amarillo) indican distancias grandes y por tanto individuos morfológicamente más diferentes.

El patrón más llamativo del gráfico es la aparición de tres bloques oscuros bien definidos a lo largo de la diagonal, lo que revela de forma visual que los datos contienen tres grupos naturales de pingüinos con alta similitud interna. Estos bloques se corresponden aproximadamente con las tres especies del dataset: el primer bloque (observaciones 0–150 aproximadamente) agrupa a los pingüinos más pequeños, el segundo bloque intermedio (150–220) recoge un grupo de tamaño moderado, y el tercer bloque (220–338) concentra los individuos más grandes y morfológicamente distintos del resto.

Fuera de la diagonal, las zonas más claras reflejan las mayores distancias entre grupos, especialmente entre el tercer bloque y los dos primeros, lo que indica que ese grupo es el más diferente morfológicamente. Este patrón de bloques es una señal clara de que el clustering tendrá una estructura bien definida y anticipa que 3 grupos es un número razonable para segmentar el dataset, hipótesis que se confirmará posteriormente con el dendrograma y los métodos de validación.

Dendrograma




Imagen 14 Dendrograma

Este gráfico combina el heatmap de distancias con un dendrograma jerárquico en ambos ejes, reordenando las observaciones según el agrupamiento obtenido mediante el método de enlace promedio (*average linkage*). Esta representación permite visualizar simultáneamente la estructura de similitudes y la jerarquía de grupos.

El dendrograma superior y lateral muestran claramente dos ramas principales que se dividen a su vez en tres grupos bien diferenciados, identificables por los bloques de color amarillo-claro (alta similitud interna) en la diagonal. El primer grupo, de mayor tamaño, ocupa la parte superior izquierda del heatmap y agrupa a los pingüinos morfológicamente más similares entre sí. El segundo grupo, de tamaño intermedio, aparece en el bloque central. El tercer grupo, visible en la esquina inferior derecha, es el más compacto y homogéneo internamente, con distancias internas notablemente bajas.

Las zonas de color azul oscuro fuera de los bloques diagonales confirman las grandes diferencias entre grupos, especialmente entre el tercer grupo y los dos primeros. Este patrón refuerza la conclusión anticipada por el heatmap anterior: la estructura natural

del dataset apunta a 3 clusters, que se corresponderán con las tres especies de pingüinos, como se verificará en los apartados siguientes.

Dendrograma — Clustering Jerárquico (Ward)




Imagen 15 Clustering Jerárquico Ward

El dendrograma obtenido mediante el método de Ward representa gráficamente el proceso de fusión de observaciones en grupos, donde el eje vertical indica la distancia a la que se produce cada unión. Cuanto más alta es la línea de fusión, más diferentes son los grupos que se están uniendo.

Se observan claramente **dos ramas principales** separadas por la línea azul, que se produce a una altura aproximada de 40, siendo el salto más grande de todo el dendrograma. Esto indica que esos dos supergrupos son los más diferentes entre sí morfológicamente. A su vez, la rama derecha (verde) se divide en dos subgrupos a una altura de aproximadamente 18, mientras que la rama izquierda (naranja) se mantiene como un grupo más compacto con fusiones a alturas inferiores a 12.

El criterio para elegir el número de clusters consiste en cortar el dendrograma por el salto de altura más grande, es decir, donde la distancia entre fusiones es mayor. En este caso, el salto más pronunciado se produce entre las alturas 18 y 40, lo que sugiere que el corte óptimo se sitúa justo por debajo de la línea azul, dando lugar a **3 grupos diferenciados**: el grupo naranja (izquierda), y los dos subgrupos verdes (derecha). Esta elección de $k=3$ es coherente con todo lo observado anteriormente en el heatmap de distancias y con la estructura biológica real del dataset, que contiene exactamente tres especies de pingüinos.

Una vez determinado visualmente que 3 es el número óptimo de grupos, se procede a asignar cada observación a su cluster correspondiente mediante la función `fcluster()` con el criterio `maxclust`, que corta el dendrograma de forma que se obtengan exactamente 3 grupos. Las etiquetas resultantes se incorporan al DataFrame original como una nueva columna `Cluster3`, lo que permite vincular cada pingüino con su grupo asignado y facilita la comparación con las especies reales en los análisis posteriores.




Imagen 16 Asignación de cluster en el plano PCA

Con el objetivo de visualizar espacialmente los grupos obtenidos, se proyectan las asignaciones del clustering jerárquico sobre el plano formado por las dos primeras componentes principales. El gráfico resultante muestra una separación clara y coherente entre los tres clusters. El **Cluster 1** (azul) se concentra en el extremo derecho del eje CP1, agrupando a los pingüinos de mayor tamaño corporal. El **Cluster 2** (naranja) ocupa la zona central-izquierda con valores elevados en CP2, diferenciándose del resto principalmente por la morfología del pico. El **Cluster 3** (verde) se sitúa en el extremo izquierdo de CP1, correspondiendo a los individuos más pequeños morfológicamente. Esta distribución es completamente coherente con los resultados del dendrograma y anticipa una correspondencia muy alta con las tres especies reales del dataset.

AGRUPAMIENTO K-MEANS Y SELECCIÓN DEL NÚMERO ÓPTIMO DE GRUPOS MEDIANTE EL MÉTODO DEL CODO

El algoritmo K-Means es una técnica de agrupamiento no jerárquico que divide el conjunto de datos en k grupos, asignando cada observación al cluster cuyo centroide es más cercano en términos de distancia euclidiana, e iterando hasta minimizar la varianza interna total de los grupos, medida a través del WCSS (WITHIN-CLUSTER SUM OF SQUARES).

Con el fin de determinar el número óptimo de clusters de forma objetiva, se aplica el método del codo, que consiste en ejecutar K-Means para un rango de valores de k, en este caso de 1 a 10, y representar el WCSS resultante para cada uno.




Imagen 17 Método del codo

Como se observa en el gráfico, la curva presenta una caída muy pronunciada entre $k=1$ ($WCSS \approx 1325$) y $k=3$ ($WCSS \approx 370$), punto a partir del cual la reducción se vuelve progresivamente menor y la curva comienza a aplanarse. Este cambio de pendiente, que da nombre al método, se sitúa claramente en **$k=3$** , indicando que añadir más clusters a partir de ese valor no aporta una mejora sustancial en la compacidad de los grupos y no justifica el incremento en la complejidad del modelo.

Este resultado es plenamente coherente con las conclusiones obtenidas en el apartado anterior mediante el clustering jerárquico, donde el dendrograma ya señalaba 3 como el número natural de grupos. Una vez determinado $k=3$ como valor óptimo, se procede a ajustar el modelo K-Means definitivo sobre los datos estandarizados, obteniendo las etiquetas de cluster para cada observación y proyectando los resultados sobre el plano PCA para su visualización e interpretación.




Imagen 18 K-Means ($k=3$)

La proyección del agrupamiento K-Means sobre el plano PCA muestra una separación espacial clara y bien definida entre los tres clusters. El **Cluster 1** (naranja) se concentra en la zona derecha del eje CP1, agrupando a los pingüinos de mayor tamaño corporal, con aletas largas y elevada masa corporal. El **Cluster 0** (azul) ocupa la zona central del gráfico con valores positivos en CP2, diferenciándose del resto principalmente por la morfología del pico. El **Cluster 2** (verde) se sitúa en el extremo izquierdo de CP1, correspondiendo a los individuos más pequeños morfológicamente.

La superposición entre clusters es mínima, lo que indica que K-Means ha encontrado grupos compactos y bien diferenciados. Esta distribución es prácticamente idéntica a la obtenida con el clustering jerárquico, confirmando que ambos métodos convergen hacia la misma estructura subyacente en los datos y que la elección de $k=3$ es robusta e independiente del algoritmo utilizado.

VALIDACIÓN DEL AGRUPAMIENTO MEDIANTE MÉTRICAS COMO LA SILUETA Y EVALUACIÓN DE LA CALIDAD DE LOS GRUPOS

Para evaluar la calidad del agrupamiento obtenido se aplican dos métricas de validación: el coeficiente de silueta por k y el silhouette plot para $k=3$.




Imagen 19 Silhouette Method

El gráfico de silueta por k muestra que el score más elevado se alcanza en $k=2$ (≈ 0.53), lo que matemáticamente indicaría que dos grupos son los más compactos y separados. Sin embargo, $k=3$ obtiene un score de ≈ 0.45 , que sigue siendo un valor considerablemente bueno, y es la elección más coherente tanto con el contexto biológico del dataset —que contiene tres especies diferenciadas— como con los resultados obtenidos previamente mediante el dendrograma y el método del codo. A partir de $k=3$, el coeficiente decrece de forma sostenida hasta $k=10$, lo que confirma que incrementar el número de grupos más allá de 3 deteriora progresivamente la calidad del agrupamiento.




Imagen 20 Silhouette Plot for Clusters

El silhouette plot para $k=3$ desglosa el coeficiente de silueta individualmente para cada observación dentro de su cluster. El cluster 1 (naranja) es el más numeroso y presenta los valores más altos y uniformes, indicando una cohesión interna elevada y una buena separación respecto a los demás grupos. El cluster 2 (amarillo) muestra también una buena calidad general, aunque con mayor variabilidad entre sus miembros. El cluster 0 (morado) es el más pequeño y presenta algunos valores negativos o próximos a cero, lo que sugiere que ciertos individuos se encuentran en la frontera entre clusters y podrían estar igualmente bien asignados a otro grupo. Este comportamiento es esperable dado que Adelie y Chinstrap comparten un tamaño corporal similar y su separación recae principalmente en CP2.

En conjunto, los resultados de validación confirman que la solución de $k=3$ captura de forma efectiva la estructura inherente del dataset, con grupos internamente cohesionados y bien diferenciados entre sí, siendo la elección más equilibrada entre calidad estadística e interpretabilidad biológica.

Para evaluar la efectividad del algoritmo en capturar la estructura inherente de los datos, se comparan las asignaciones de K-Means con las etiquetas reales de especie mediante una tabla de contingencia. Los resultados son los siguientes:

	Adelie	Chinstrap	Gentoo
Cluster 0	22	64	0
Cluster 1	0	0	119
Cluster 2	124	5	0

El algoritmo demuestra una capacidad notable para recuperar la estructura biológica real del dataset sin haber utilizado en ningún momento las etiquetas de especie. El **Cluster 1** identifica a la especie Gentoo con una precisión del **100%**, lo que refleja

que esta especie es morfológicamente tan distinta del resto que el algoritmo la separa de forma perfecta. El **Cluster 2** recoge a 124 de los 146 individuos Adelie (85% de precisión), con solo 5 Chinstrap mal asignadas. El **Cluster 0** agrupa principalmente a Chinstrap (63 de 85 individuos, 74% de precisión), aunque incluye 22 Adelie que el algoritmo confunde con Chinstrap.

Esta confusión entre Adelie y Chinstrap es esperable y biológicamente coherente: ambas especies tienen un tamaño corporal similar, por lo que se solapan en CP1, y su diferenciación recae principalmente en CP2, que captura la morfología del pico. K-Means, al basarse exclusivamente en distancias euclidianas en el espacio de las 4 variables originales, tiene más dificultad para capturar esta distinción sutil. En conjunto, el algoritmo logra una separación altamente efectiva de la estructura inherente del dataset, especialmente en lo que respecta a Gentoo, y comete errores únicamente en la frontera natural entre las dos especies más similares morfológicamente.

COMPARACIÓN ENTRE AGRUPAMIENTO JERÁRQUICO Y K-MEANS EN LAS ASIGNACIONES DE GRUPOS

Tabla K-Means:

	Adelie	Chinstrap	Gentoo
Cluster 0	22	64	0
Cluster 1	0	0	119
Cluster 2	124	5	0

Tabla Jerárquico

	Adelie	Chinstrap	Gentoo
Cluster 1	0	0	119
Cluster 2	0	57	0
Cluster 3	146	11	0

Para cuantificar de forma objetiva la comparación entre ambos métodos, se calcula el accuracy del clustering mediante el algoritmo húngaro, que encuentra la asignación óptima entre etiquetas de cluster y especies reales independientemente del orden de numeración. Los resultados son los siguientes:

Accuracy Clustering Jerárquico: 96.70%		
Accuracy K-Means: 91.89%		
=== COMPARACIÓN DE MÉTODOS ===		
	Método	Accuracy (%) Errores
	Jerárquico (Ward)	96.70 11
	K-Means (k=3)	91.89 27

Imagen 21 Comparativa entre métodos

El clustering jerárquico con enlace de Ward obtiene un accuracy del 96.70%, cometiendo únicamente 11 errores sobre las 333 observaciones del dataset. K-Means, con un accuracy del 91.89%, comete 27 errores, es decir, más del doble que el método jerárquico. Ambos resultados son notablemente altos para un algoritmo no supervisado que en ningún momento ha tenido acceso a las etiquetas de especie, lo que demuestra que la estructura morfológica de las tres especies es suficientemente diferenciada como para ser recuperada de forma casi perfecta. La ventaja del método jerárquico en este caso se debe probablemente a que el criterio de Ward, al minimizar la varianza interna en cada fusión, genera clusters más compactos y equilibrados que se ajustan mejor a la forma natural de los grupos en este dataset.

INTERPRETACIÓN DE LOS GRUPOS IDENTIFICADOS Y ANÁLISIS DE PATRONES ENTRE LAS ESPECIES DE PINGÜINOS

Para interpretar el significado de cada cluster en el contexto de las especies de pingüinos, se analizan los centroides obtenidos en las unidades originales de cada variable morfológica:

	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g
Cluster 0	47.66	18.75	196.92	3898.24
Cluster 1	47.57	15.0	217.24	5092.44
Cluster 2	38.28	18.12	188.63	3593.8

El **Cluster 1** corresponde inequívocamente a la especie **Gentoo**. Sus valores son los más extremos en tres de las cuatro variables: aleta más larga (217.24mm), mayor masa corporal (5092g) y pico menos profundo (15.0mm). Son los pingüinos más grandes y pesados del dataset, con una morfología claramente diferenciada del resto, lo que explica por qué ambos algoritmos los identifican con un 100% de precisión.

El **Cluster 0** se corresponde principalmente con la especie **Chinstrap**. Presenta un pico largo (47.66mm) y notablemente profundo (18.75mm), siendo este último valor

el más alto de los tres grupos, lo que lo distingue morfológicamente de Gentoo a pesar de tener una longitud de pico similar. Su masa corporal (3898g) y longitud de aleta (196.92mm) son intermedias entre los otros dos grupos.

El **Cluster 2** agrupa fundamentalmente a la especie **Adelie**. Es el grupo morfológicamente más pequeño en todas las variables: pico más corto (38.28mm), aleta más corta (188.63mm) y menor masa corporal (3593g). La profundidad del pico (18.12mm) es similar a la de Chinstrap, lo que explica la confusión entre ambas especies en la frontera de los clusters.

En conjunto, los tres grupos identificados reflejan con gran fidelidad las diferencias morfológicas reales entre las tres especies de pingüinos, confirmando que el tamaño corporal general —capturado por CP1— es el factor dominante de diferenciación, mientras que la morfología específica del pico —capturada por CP2— permite distinguir a Chinstrap de Adelie cuando el tamaño no es suficiente.

RESUMEN DE HALLAZGOS, CONCLUSIONES Y LIMITACIONES DEL ANÁLISIS DE AGRUPAMIENTO

El presente análisis ha permitido explorar la estructura morfológica del dataset Palmer Penguins mediante la combinación de técnicas de reducción de dimensionalidad y agrupamiento no supervisado, obteniendo resultados altamente satisfactorios en todos los apartados.

En primer lugar, el Análisis de Componentes Principales demostró que las cuatro variables morfológicas del dataset pueden resumirse eficientemente en tan solo dos componentes principales que explican conjuntamente el **88.09%** de la varianza total. CP1 captura el tamaño corporal general del pingüino, mientras que CP2 recoge las diferencias en la morfología del pico, permitiendo distinguir visualmente las tres especies en el plano bidimensional sin haber utilizado en ningún momento las etiquetas de especie.

En cuanto al clustering, tanto el método jerárquico con enlace de Ward como K-Means con $k=3$ convergieron hacia la misma solución de tres grupos, confirmando que esta estructura es robusta e independiente del algoritmo utilizado. La elección de $k=3$ fue respaldada de forma consistente por el dendrograma, el heatmap de distancias, el método del codo y el coeficiente de silueta. La comparación con las especies reales reveló que el clustering jerárquico alcanzó un **accuracy del 96.70%** (11 errores), superando a K-Means con un **91.89%** (27 errores). En ambos casos, la especie Gentoo fue identificada con una precisión del 100%, mientras que la mayor fuente de error se concentró en la frontera entre Adelie y Chinstrap, dos especies morfológicamente similares en tamaño que solo se diferencian claramente por la morfología del pico.

LIMITACIONES Y DESAFÍOS

A pesar de los buenos resultados obtenidos, el análisis presenta algunas limitaciones que conviene señalar. En primer lugar, el solapamiento morfológico entre Adelie y Chinstrap representa el principal desafío del clustering en este

dataset, ya que ambas especies comparten un tamaño corporal similar y su diferenciación requiere capturar matices en la forma del pico que los algoritmos basados en distancias euclidianas no siempre detectan con precisión. En segundo lugar, K-Means es sensible a la inicialización aleatoria de los centroides, lo que puede producir soluciones ligeramente distintas entre ejecuciones si no se fija una semilla, aspecto que se ha controlado mediante el parámetro `random_state=0`. En tercer lugar, el método del codo sugería técnicamente $k=2$ como solución con mayor silueta (≈ 0.53), mientras que el contexto biológico y el dendrograma apuntaban a $k=3$, lo que pone de manifiesto que las métricas estadísticas deben interpretarse siempre en conjunción con el conocimiento del dominio. Finalmente, el dataset excluye las observaciones con valores perdidos, lo que podría introducir un sesgo si los datos faltantes no son aleatorios.

El análisis demuestra que la morfología de los pingüinos contiene una estructura natural clara y bien definida que los algoritmos de clustering son capaces de recuperar con gran fidelidad, validando tanto la utilidad del PCA como herramienta de visualización como la efectividad de los métodos de agrupamiento para descubrir patrones en datos no etiquetados.